

# DATA ENGINEERING

## Analyse des flux Mobile Money en Côte d'Ivoire

Pipeline ETL · Schéma en étoile · Airflow · Docker

---

Notre trinôme · Projet de Fin de Module

Encadré par : GOUAH Tato Serge · Juin 2025

# Plan de la présentation

1. Contexte et problématique métier (2 min)
2. Architecture du pipeline (2 min)
3. Dataset et audit de qualité (2 min)
4. Pipeline ETL : transformations clés (2 min)
5. Modélisation : schéma en étoile (2 min)
6. Analyses SQL et résultats (2 min)
7. Dashboard et visualisations (1 min)
8. Orchestration : Airflow + Docker (1 min)
9. Difficultés et conclusion (1 min)

# 1. Contexte : Mobile Money en Côte d'Ivoire

4 opérateurs majeurs : MTN CI, Orange Money, Moov Africa, Wave

Plus de 20 millions d'utilisateurs en CI


~12 millions de transactions par jour

Secteur stratégique : télécoms, fintech, banques, retail

Notre mission : Data Engineer chez un agrégateur de paiements à Abidjan

Objectif : transformer 100 000 transactions brutes en indicateurs actionnables

## 2. Architecture du pipeline



Stack : Python/Pandas → Supabase PostgreSQL → dbt → Airflow → Docker → GitHub Actions

### 3. Dataset et audit de qualité

#### Fichier :

**Data2\_transactions\_mobile\_money\_100k.c**

**sv**

100 000 lignes, 12 colonnes, 13 Mo

Période : janvier à juin 2024

4 opérateurs : MTN CI, Orange Money, Moov  
Africa, Wave

5 types d'opérations : Dépôt, Retrait, Transfert,  
etc.

10 zones géographiques (Abidjan + intérieur)

#### Problèmes détectés à l'audit :

- ✗ 2 000 NaN sur frais\_fcfa (2%)
- ✗ 4 000 NaN sur zone\_beneficiaire (4%)
- ✗ 3 000 NaN sur id\_agent (3%)
- ✗ 200 montants aberrants ( $\leq 0$  FCFA)
- ✗ Type date\_heure incorrect (str)

✓ Résultat : 99 800 lignes propres, 0 NaN, 200 aberrations supprimées, types corrigés

## 4. ETL — Extraction et audit

Chargement CSV avec `pandas.read_csv()` en 0.33 seconde

Inspection des types, valeurs manquantes, statistiques

Identification des colonnes à corriger et enrichir

Code clé :

```
import pandas as pd
df = pd.read_csv('transactions_mobile_money_100k.csv')
print(df.info())
print(df.isnull().sum())
print(df['montant_fcfa'].describe())
```

## 4. ETL — Nettoyage et enrichissement

### Nettoyage :

date\_heure → datetime64

Chaînes vides → NaN → fillna()

frais\_fcfa NaN → 0

zone\_beneficiaire NaN → Zone inconnue

id\_agent NaN → AGT-INCONNU

200 lignes aberrante supprimées

### Enrichissement :

montant\_net\_fcfa (montant - frais)

taux\_frais\_pct (%)

categorie\_montant (Micro/Petit/Moyen/Gros)

tranche\_horaire (Matin/Soirée/Nuit...)

inter\_ville (même ville ? 0/1)

heure, jour\_semaine, mois

✓ 5 tests qualité automatiques : complétude, unicité, validité, conformité, typage

Taux de succès global : 80.2% | Volume total : 14,8 milliards FCFA

## 4. ETL — Chargement Supabase

Supabase : base PostgreSQL cloud gratuite (sans CB)

Chargement par lots de 5 000 lignes (chunks)

99 800 lignes chargées en 62 secondes


Tables créées : transactions, agg\_operateur, agg\_type, agg\_zone

**Code clé (chargement par chunks) :**

```
chunks = [df[i:i+5000] for i in range(0, len(df), 5000)]  
for chunk in chunks:  
    chunk.to_sql('transactions', conn, if_exists='append', method='multi')
```



## 5. Modélisation : Schéma en étoile



60 033 lignes dans faits\_transactions · Clés étrangères REFERENCES

## 6. Analyses SQL — Résultats

### Q1 - Volume par opérateur :

Wave : 2,16 Mds FCFA | MTN CI : 2,12 Mds | Moov : 2,12 Mds | Orange : 2,10 Mds

### Q2 - Tendence mensuelle :

Volume stable ~1,4 Mds/mois · Légère baisse en juin (vacances)

### Q3 - Top 5 agents par volume :

AGT0113 : 88,2 M FCFA | AGT0074 : 85,9 M | AGT0052 : 84,9 M

### Q4 - Taux d'échec par opérateur (CTE + RANK + LAG) :

Moov Africa 10.1% > Orange 10.0% > MTN 9.8% > Wave 9.7%



Fonctions de fenêtre utilisées : RANK() OVER, LAG(), PARTITION BY, CTE

## 7. Tableau de bord — 5 graphiques

Volume mensuel par opérateur (barres empilées)

Parts de marché par volume (camembert) ~25% chacun

Volume par tranche horaire (courbe) — pics à 8h et 19h

Taux de succès par opérateur (barres horizontales) ~80%

Distribution montants par catégorie (violin, échelle log)



### Interprétation métier :

Marché équilibré entre 4 opérateurs · Pics d'activité matin et soir · Majorité de petits montants

## 8. Orchestration : Apache Airflow + Docker

### DAG : pipeline\_mobile\_money\_ci

Schedule : 0 23 \* \* \* (23h00 chaque jour)

5 tâches enchaînées :

extract\_csv → clean\_data → load\_supabase  
→ run\_dbt → generate\_report

3 retries, alertes email, timeout 2h

Callbacks : on\_failure, on\_success, on\_retry

### Conteneurisation Docker :

Dockerfile : python:3.10-slim (~130 Mo)

docker-compose : 3 services

postgres (metadata Airflow)

airflow-webserver (interface)

airflow-scheduler (planificateur)

Volumes partagés dags/ et data/

# Bonus : CI/CD GitHub Actions + dbt

## GitHub Actions CI/CD :

Déclenché à chaque git push (main/develop)

Job 1 : quality-checks (flake8, pytest)

Job 2 : docker-build (si tests OK)

Cache pip pour builds plus rapides

## dbt (Data Build Tool) :

Modèle SQL déclaratif : perf\_operateurs

Vue analytique : volume mensuel par opérateur

Tests de qualité : not\_null, unique

dbt run + dbt test automatisés



**Tous les livrables sur GitHub : <https://github.com/moise2024/mobile-money-ci>**

README · Notebook .ipynb · DAG Airflow · Dockerfile · docker-compose · dbt · Rapport PDF · Captures

## 9. Difficultés et solutions

1

**Gestion des accents**

Succès vs Succes, Échec vs Echech → f-string avec UTF-8

2

**Types datetime64**

ns vs us selon version Pandas → détection dynamique

3

**Chargement Supabase**

Timeout du plan gratuit → chunks de 5000 lignes

4

**Limitation espace disque**

/tmp plein → liaison directe avec les fichiers source

5

**Token GitHub**

Scope workflow manquant → ajout manuel sur GitHub

6

**Mappage dates**

60k faits vs 99k transactions → jointure dim\_date

# Conclusion

- ✓ Pipeline ETL complet : 100 000 → 99 800 lignes propres en 0.33s
- ✓ Schéma en étoile : 4 dimensions + 1 table de faits dans Supabase
- ✓ 4 requêtes SQL analytiques dont CTE + fonctions de fenêtre
- ✓ Dashboard 5 graphiques + rapport PDF + notebook .ipynb
- ✓ DAG Airflow automatisé + Docker + CI/CD GitHub Actions
- ✓ dbt (bonus) pour la transformation déclarative

---

**Merci pour votre attention ! Questions ?**